

Efficient Net

1. 导入库

```
1 import math
2 import copy
3 from functools import partial
4 from collections import OrderedDict
5 from typing import Optional, Callable
6 import torch
7 import torch.nn as nn
8 from torch import Tensor
9 from torch.nn import functional as F
```

2. 定义辅助函数

定义一个函数来确保所有层的通道数是8的倍数。

```
1 def _make_divisible(ch, divisor=8, min_ch=None):
2     # 将通道数调整为8的倍数
3     if min_ch is None:
4         min_ch = divisor # 设置最小通道数为divisor
5     # 计算新的通道数
6     new_ch = max(min_ch, int(ch + divisor / 2) // divisor * divisor)
7     # 如果新的通道数小于原通道数的90%，则增加divisor
8     if new_ch < 0.9 * ch:
9         new_ch += divisor
10    return new_ch # 返回调整后的通道数
```

定义 `drop_path` 函数，用于实现随机深度。

```
1 def drop_path(x, drop_prob: float = 0., training: bool = False):
2     # 如果没有dropout或不是训练状态，直接返回输入
3     if drop_prob == 0. or not training:
4         return x
5     keep_prob = 1 - drop_prob # 计算保持概率
6     shape = (x.shape[0],) + (1,) * (x.ndim - 1) # 创建随机张量的形状
7     # 创建一个随机张量，应用保持概率
```

```

8     random_tensor = keep_prob + torch.rand(shape, dtype=x.dtype,
        device=x.device)
9     random_tensor.floor_() # 取整
10    output = x.div(keep_prob) * random_tensor # 进行dropout
11    return output # 返回经过dropout的输出

```

3. 定义层类

创建用于卷积、批量归一化和激活函数的类。

```

1 class DropPath(nn.Module):
2     def __init__(self, drop_prob=None):
3         # 初始化DropPath层
4         super(DropPath, self).__init__()
5         self.drop_prob = drop_prob # 设置dropout概率
6
7     def forward(self, x):
8         # 前向传播, 应用drop_path
9         return drop_path(x, self.drop_prob, self.training) # 返回经过drop_path处
        理的输出

```

定义 `ConvBNActivation` 类, 将卷积、批量归一化和激活结合在一起。

```

1 class ConvBNActivation(nn.Sequential):
2     def __init__(self, in_channels: int, out_channels: int, kernel_size: int =
        3, stride: int = 1,
3         groups: int = 1, norm_layer: Optional[Callable[...,
        nn.Module]] = None,
4         activation_layer: Optional[Callable[..., nn.Module]] = None):
5         padding = (kernel_size - 1) // 2 # 计算填充
6         if norm_layer is None:
7             norm_layer = nn.BatchNorm2d # 默认使用BatchNorm
8         if activation_layer is None:
9             activation_layer = nn.SiLU # 默认使用Swish激活函数
10
11        # 调用父类构造函数, 创建卷积、批量归一化和激活层的顺序容器
12        super(ConvBNActivation, self).__init__(
13            nn.Conv2d(in_channels=in_channels, out_channels=out_channels,
14                kernel_size=kernel_size, stride=stride, padding=padding,
15                groups=groups, bias=False), # 卷积层
16            norm_layer(out_channels), # 批量归一化层
17            activation_layer() # 激活层
18        )

```

该类用于封装卷积、批量归一化和激活函数，便于在后续网络结构中重复使用。该模块设置了卷积层的超参数，以便高效处理输入特征，同时保持输出特征图的尺寸一致。

定义 `SqueezeExcitation` 类，用于压缩和激励机制。

```
1 class SqueezeExcitation(nn.Module):
2     def __init__(self, input_c: int, expand_c: int, squeeze_factor: int = 4):
3         super(SqueezeExcitation, self).__init__()
4         squeeze_c = input_c // squeeze_factor # 计算压缩后的通道数
5         # 定义两个全连接层
6         self.fc1 = nn.Conv2d(expand_c, squeeze_c, 1) # 第一个全连接层
7         self.ac1 = nn.SiLU() # 激活函数
8         self.fc2 = nn.Conv2d(squeeze_c, expand_c, 1) # 第二个全连接层
9         self.ac2 = nn.Sigmoid() # Sigmoid激活函数
10
11     def forward(self, x: Tensor) -> Tensor:
12         # 前向传播, 进行Squeeze和Excitation
13         scale = F.adaptive_avg_pool2d(x, output_size=(1, 1)) # 池化
14         scale = self.fc1(scale) # 通过第一个全连接层
15         scale = self.ac1(scale) # 激活
16         scale = self.fc2(scale) # 通过第二个全连接层
17         scale = self.ac2(scale) # 激活
18         return scale * x # 返回加权后的输出
```

该模块通过全局平均池化减少空间维度，然后进行缩放以突出重点特征。在 EfficientNet 中，SE模块会在特定位置插入，用于增强网络的特征表示能力。

4. 定义倒残差块

创建倒残差块的配置类和具体实现类。

```
1 class InvertedResidualConfig:
2     def __init__(self, in_channels: int, out_channels: int, kernel_size: int,
3         stride: int,
4         expanded_ratio: int, use_se: bool, drop_rate: float, index:
5         str,
6         width_coefficient: float):
7         # 初始化倒残差块配置
8         self.in_channels = self.adjust_channels(in_channels,
9         width_coefficient) # 输入通道数
10        self.kernel_size = kernel_size # 卷积核大小
11        self.expanded_channels = self.in_channels * expanded_ratio # 扩展通道数
```

```

9         self.out_channels = self.adjust_channels(out_channels,
width_coefficient) # 输出通道数
10        self.use_se = use_se # 是否使用SE模块
11        self.stride = stride # 步幅
12        self.drop_rate = drop_rate # dropout率
13        self.index = index # 索引
14
15        @staticmethod
16        def adjust_channels(channels: int, width_coefficient: float):
17            # 调整通道数为8的倍数
18            return _make_divisible(channels * width_coefficient, 8)

```

包含了输入输出通道、卷积核大小、步幅、扩展率等关键信息。这些参数用于构建 EfficientNet 的倒残差块，并提供灵活性来根据输入和输出需求进行调整。

```

1 class InvertedResidual(nn.Module):
2     def __init__(self, cnf: InvertedResidualConfig, norm_layer: Callable[...,
nn.Module]):
3         super(InvertedResidual, self).__init__()
4
5         if cnf.stride not in [1, 2]:
6             raise ValueError("illegal stride value.") # 检查步幅是否合法
7
8         # 判断是否使用残差连接
9         self.use_res_connect = (cnf.stride == 1 and cnf.in_channels ==
cnf.out_channels)
10        layers = OrderedDict() # 存储层的有序字典
11        activation_layer = nn.SiLU # 使用Swish激活函数
12
13        if cnf.expanded_channels != cnf.in_channels:
14            # 如果需要扩展通道，添加扩展卷积层
15            layers.update({"expand_conv": ConvBNActivation(cnf.in_channels,
cnf.expanded_channels,
16                                                            kernel_size=1,
norm_layer=norm_layer,
17
activation_layer=activation_layer)})
18
19        # 添加深度卷积层
20        layers.update({"dwconv": ConvBNActivation(cnf.expanded_channels,
cnf.expanded_channels,
21                                                    kernel_size=cnf.kernel_size,
stride=cnf.stride,
22
groups=cnf.expanded_channels, norm_layer=norm_layer,

```

```

23     activation_layer=activation_layer))
24
25     if cnf.use_se:
26         # 如果使用SE模块，添加SE层
27         layers.update({"se": SqueezeExcitation(cnf.in_channels,
cnf.expanded_channels)})
28
29         # 添加输出卷积层
30         layers.update({"project_conv": ConvBNActivation(cnf.expanded_channels,
cnf.out_channels,
31                                                         kernel_size=1,
norm_layer=norm_layer,
32     activation_layer=nn.Identity)})
33
34     self.block = nn.Sequential(layers) # 构建块
35     self.out_channels = cnf.out_channels # 输出通道数
36     self.is_strided = cnf.stride > 1 # 是否使用步幅
37
38     if self.use_res_connect and cnf.drop_rate > 0:
39         # 如果使用残差连接且需要dropout，添加DropPath
40         self.dropout = DropPath(cnf.drop_rate)
41     else:
42         self.dropout = nn.Identity() # 否则使用恒等映射
43
44     def forward(self, x: Tensor) -> Tensor:
45         # 前向传播
46         result = self.block(x) # 通过块
47         result = self.dropout(result) # 应用dropout
48         if self.use_res_connect:
49             result += x
50     return result

```

使用倒残差结构，通过多个层次的卷积和非线性变化来提取和处理特征。首先检查扩展率是否为 1，以决定是否对通道数进行扩展。然后构建一个深度卷积模块，在高维度的特征空间中对特征进行卷积操作，最后加入 SE 模块（如果启用）来增强该块的特征表达。

5. 定义EfficientNet架构

创建EfficientNet类，整合之前定义的模块。用输入 `width_coefficient` 和 `depth_coefficient` 来动态调整网络的宽度（通道数）和深度（层数），以实现效率和性能的平衡。

- 定义了 `EfficientNet` 类，继承自 `nn.Module`。

- 初始化网络结构和参数，包括宽度和深度系数，分类数量，以及 Dropout 和 Drop Connect 的概率。
- 使用默认的配置参数，构建倒残差块。

特征提取层

- 整合所有倒残差块，构建特征提取模块。
- 通过 `nn.Sequential` 将这些层组合在一起。
- 添加自适应平均池化层，以确保输出的特征图统一。

```

1 class EfficientNet(nn.Module):
2     def __init__(self, width_coefficient: float, depth_coefficient: float,
3         num_classes: int = 2,
4         dropout_rate: float = 0.2, drop_connect_rate: float = 0.2,
5         block: Optional[Callable[..., nn.Module]] = None,
6         norm_layer: Optional[Callable[..., nn.Module]] = None):
7         # 初始化EfficientNet模型
8         super(EfficientNet, self).__init__()
9
10        # 定义默认的网络配置，每个元素对应一个倒残差块的参数
11        default_cnf = [
12            [32, 16, 3, 1, 1, True, drop_connect_rate, 1], # 32输入, 16输出,
13            3x3卷积, 步幅1, 扩展率1, 使用SE
14            [16, 24, 3, 2, 6, True, drop_connect_rate, 2], # 16输入, 24输出,
15            3x3卷积, 步幅2, 扩展率6, 使用SE
16            [24, 40, 5, 2, 6, True, drop_connect_rate, 2], # 24输入, 40输出,
17            5x5卷积, 步幅2
18            [40, 80, 3, 2, 6, True, drop_connect_rate, 3], # 40输入, 80输出,
19            3x3卷积, 步幅2
20            [80, 112, 5, 1, 6, True, drop_connect_rate, 3], # 80输入, 112输出,
21            5x5卷积, 步幅1
22            [112, 192, 5, 2, 6, True, drop_connect_rate, 4], # 112输入, 192输出,
23            5x5卷积, 步幅2
24            [192, 320, 3, 1, 6, True, drop_connect_rate, 1] # 192输入, 320输
25            出, 3x3卷积, 步幅1
26        ]
27
28        # 定义一个函数来根据深度系数调整重复次数
29        def round_repeats(repeats):
30            return int(math.ceil(depth_coefficient * repeats)) # 向上取整
31
32        if block is None:
33            block = InvertedResidual # 默认使用InvertedResidual块
34
35        if norm_layer is None:

```

```

28         norm_layer = partial(nn.BatchNorm2d, eps=1e-3, momentum=0.1) # 默认
    的批量归一化层
29
30         # 使用部分函数应用, 调整通道数
31         adjust_channels = partial(InvertedResidualConfig.adjust_channels,
width_coefficient=width_coefficient)
32
33         # 用于构建倒残差块配置的部分函数
34         bneck_conf = partial(InvertedResidualConfig,
width_coefficient=width_coefficient)
35
36         b = 0 # 用于计数块的数量
37         num_blocks = float(sum(round_repeats(i[-1]) for i in default_cnf)) # 计
算总块数
38         inverted_residual_setting = [] # 存储每个倒残差块的配置
39
40         # 遍历每个阶段的配置
41         for stage, args in enumerate(default_cnf):
42             cnf = copy.copy(args) # 复制当前配置
43             for i in range(round_repeats(cnf.pop(-1))): # 根据重复次数添加多个块
44                 if i > 0:
45                     cnf[3] = 1 # 如果是重复的块, 步幅设置为1
46                     cnf[0] = cnf[1] # 输入通道数等于输出通道数
47
48                     # 更新drop_connect_rate
49                     cnf[-1] = args[-2] * b / num_blocks
50                     index = str(stage + 1) + chr(i + 97) # 创建块的索引
51                     inverted_residual_setting.append(bneck_conf(*cnf, index)) # 添
加配置
52
53                     b += 1 # 增加块计数
54
55         layers = OrderedDict() # 创建有序字典以存储层
56
57         # 添加初始卷积层
58         layers.update({
59             "stem_conv": ConvBNActivation(in_channels=3, # 输入通道为3 (RGB图像)
out_channels=adjust_channels(32), #
输出通道根据宽度系数调整
60
61             kernel_size=3, # 卷积核大小为3
62             stride=2, # 步幅为2
63             norm_layer=norm_layer) # 使用的归一化
层
64
65         })
66
67         self.features = nn.Sequential(layers) # 整合特征提取层
68         self.avgpool = nn.AdaptiveAvgPool2d(1) # 自适应平均池化层

```

6. 分类器和权重初始化

创建分类器，添加 Dropout 和全连接层。

通过遍历所有模块进行权重初始化，确保网络的稳定性和训练的有效性。

```
1     # 定义分类器
2     classifier = []
3     if dropout_rate > 0:
4         classifier.append(nn.Dropout(p=dropout_rate, inplace=True)) # 添加
Dropout层以减少过拟合
5     classifier.append(nn.Linear(last_conv_output_c, num_classes)) # 添加线性分类
层
6     self.classifier = nn.Sequential(*classifier) # 整合分类器
7
8     # 初始化权重
9     for m in self.modules():
10        if isinstance(m, nn.Conv2d):
11            nn.init.kaiming_normal_(m.weight, mode="fan_out") # 卷积层权重初始化
12            if m.bias is not None:
13                nn.init.zeros_(m.bias) # 偏置初始化为0
14        elif isinstance(m, nn.BatchNorm2d):
15            nn.init.ones_(m.weight) # 归一化层权重初始化为1
16            nn.init.zeros_(m.bias) # 偏置初始化为0
17        elif isinstance(m, nn.Linear):
18            nn.init.normal_(m.weight, 0, 0.01) # 线性层权重初始化
19            nn.init.zeros_(m.bias) # 偏置初始化为0
```

7. 前向传播方法

定义前向传播方法，依次通过特征提取层、池化层、展平层和分类器。

```
1     def forward(self, x: Tensor) -> Tensor:
2         x = self.features(x) # 通过特征提取层
3         x = self.avgpool(x) # 进行自适应平均池化
4         x = torch.flatten(x, 1) # 展平为一维向量
5         x = self.classifier(x) # 通过分类器
6         return x # 返回输出
```

8. EfficientNet 的不同版本函数

通过多个函数创建不同版本的 EfficientNet，每个函数根据需求调整网络的宽度、深度。


```
1 def efficientnet_b0(num_classes=2):
2     # 创建 EfficientNet B0 版本, 输入图像大小为 224x224
3     return EfficientNet(width_coefficient=1.0,
4                           depth_coefficient=1.0,
5                           dropout_rate=0.2,
6                           num_classes=num_classes)
7
8 def efficientnet_b1(num_classes=2):
9     # 创建 EfficientNet B1 版本, 输入图像大小为 240x240
10    return EfficientNet(width_coefficient=1.0,
11                        depth_coefficient=1.1,
12                        dropout_rate=0.2,
13                        num_classes=num_classes)
14
15 def efficientnet_b2(num_classes=2):
16     # 创建 EfficientNet B2 版本, 输入图像大小为 260x260
17     return EfficientNet(width_coefficient=1.1,
18                         depth_coefficient=1.2,
19                         dropout_rate=0.3,
20                         num_classes=num_classes)
21
22 def efficientnet_b3(num_classes=2):
23     # 创建 EfficientNet B3 版本, 输入图像大小为 300x300
24     return EfficientNet(width_coefficient=1.2,
25                         depth_coefficient=1.4,
26                         dropout_rate=0.3,
27                         num_classes=num_classes)
28
29 def efficientnet_b4(num_classes=2):
30     # 创建 EfficientNet B4 版本, 输入图像大小为 380x380
31     return EfficientNet(width_coefficient=1.4,
32                         depth_coefficient=1.8,
33                         dropout_rate=0.4,
34                         num_classes=num_classes)
35
36 def efficientnet_b5(num_classes=2):
37     # 创建 EfficientNet B5 版本, 输入图像大小为 456x456
38     return EfficientNet(width_coefficient=1.6,
39                         depth_coefficient=2.2,
40                         dropout_rate=0.4,
41                         num_classes=num_classes)
42
43 def efficientnet_b6(num_classes=2):
44     # 创建 EfficientNet B6 版本, 输入图像大小为 528x528
45     return EfficientNet(width_coefficient=1.8,
46                         depth_coefficient=2.6,
47                         dropout_rate=0.5,
```

```
48         num_classes=num_classes)
49
50 def efficientnet_b7(num_classes=2):
51     # 创建 EfficientNet B7 版本, 输入图像大小为 600x600
52     return EfficientNet(width_coefficient=2.0,
53                          depth_coefficient=3.1,
54                          dropout_rate=0.5,
55                          num_classes=num_classes)
```